

Обоснование итоговых моделей

Технический рассказ для защиты проекта ЛЦТ-2026. Данные и артефакты проверены по состоянию на 28 сентября 2026 года.

1. Главная мысль

Мы построили модуль распознавания строительной техники из двух независимо обучаемых частей: YOLO26x определяет положение объекта, ConvNeXt-small определяет его категорию и может отклонить неизвестный объект. Выбор моделей и аугментаций опирается на серию сравнений, а финальная адаптация учитывает проблемы конкретного домена: маленькие объекты, неполную разметку кранов, нехватку буровых установок и несоответствие публичных изображений реальным камерам.

Корректное позиционирование в продукте: YOLO 640 - базовый режим. YOLO 960 - режим повышения качества на малых объектах и сложных целевых кадрах. Это две версии одной архитектуры YOLO26x с разными дообученными весами и разрешением, а не модели разных размеров backbone.

Этот ML-блок закрывает обнаружение и классификацию техники. Связь с календарным графиком, предупреждения и интерфейс нужно показать в общей демонстрации проекта. Сам по себе высокий F1 классификатора не подтверждает качество предупреждений о нарушениях. [S0]

2. Архитектура и её обоснование

Последовательность обработки: снимок; детектор YOLO; bbox; RGB-кропы; ConvNeXt; известная категория либо unknown; список наблюдаемой техники для последующих правил.

Компонент	Что делает	Зачем выделен отдельно
YOLO26x 640 / 960	Находит bbox единого класса object	Разметка разных датасетов сводится к одной задаче локализации
Подготовка кропа	Вырезает bbox, сохраняет пропорции, приводит к 224×224	Классификатор получает единый формат без растягивания техники
ConvNeXt-small	Определяет 22 известных класса и вероятность unknown	Категории и новые примеры можно развивать независимо от детектора
Правило отклонения	Отклоняет unknown и person в прикладном выводе	Посторонний объект не обязан становиться одним из классов техники
Выходной контракт	bbox, класс, уверенность, причина отклонения, исходный кадр	Наблюдение можно проверить и привязать к этапу работ

В финальном инференсе кроп получает aspect-preserving letterbox 224×224, фон 114, нормализацию ImageNet из checkpoint. Аугментации работают только при обучении. Детекторная уверенность и вероятность класса сохраняются отдельно. Unknown определяется порогом 0,011581308208405972, подобранным на validation последнего классификатора. **other_vehicle** - известный класс транспорта, **unknown** - отдельный выход, их нельзя смешивать. [S10, S13]

Мы проверили и альтернативу: многоклассовый YOLO против object-YOLO с ConvNeXt на предсказанных кропах. После дополнительного обучения объединённый class-aware AP был 58,89% у многоклассовой YOLO и 59,46% у каскада. На ExtCon - 34,28% и 43,60% соответственно. Это поддерживает выбор каскада, но сравнивает системы: ConvNeXt дополнительно использовала датасеты №3 и №4. Оно не доказывает, что двухэтапная архитектура всегда лучше при равном объёме обучающих данных. [S8]

3. Почему выбрали семейство YOLO26x

Начальный скрининг включал **35 доступных YOLO-чекпойнтов**, в том числе семейства v5, v8, v9, v10, 11, 12, 26, World и YOLOE. Это 35 вариантов весов, а не 35 принципиально разных архитектур. Все дообучали на одной выборке: 3 200 HF и 3 350 Kaggle изображений, выбранных из одинаковых 20% train. Проводили 10 эпох при 640 px, batch 16, FP32, AdamW. В этом коротком скрининге оценивали EMA последней эпохи, без early stopping. На двух H100 разные модели обучались независимо. [S1]

Оценка скрининга: 757 HF test + первая лексикографическая половина Kaggle valid, 1 614 изображений. Pooled AP пересчитывался по объединению предсказаний и GT, а не как среднее процентов по датасетам.

Чекпойнт	HF test, %	Kaggle test, %	Объединённый AP, %
yolo26x-objv1-150	67,83	55,81	58,10
yolo26l	69,75	55,04	57,99
yolo26s	70,96	54,05	57,65
yolo26x	68,79	54,45	57,23
yolov8l-worldv2	70,43	52,27	56,23

Решение: продолжить эксперименты с YOLO26x-objv1-150, YOLO26l и YOLO26s. Небольшой разрыв в скрининге не давал основания сразу отбросить l и s, поэтому проверка аугментаций охватывала всю тройку.

После перехода на полные train двух источников и season результаты изменились следующим образом. Здесь 32 706 train-изображений после исключения 50 точных копий held-out кадров, validation 3 138, test 2 371. Лучшую эпоху выбирали на validation, максимум 20 эпох, patience 5. [S4]

Финалист	HF test, %	Kaggle test, %	Объединённый AP, %
yolo26x-objv1-150	76,93	62,23	65,23
yolo26l	76,39	60,22	63,48
yolo26s	76,34	57,00	60,94

На этом этапе x дал более заметный отрыв от l и s. Поэтому последующие исследования данных и разрешения проводили на YOLO26x. Это обоснование выбора backbone, а не попытка объявить каждую следующую итерацию лучше по любой метрике.

4. Как выбирали аугментации YOLO

Сначала сравнили 6 дополнительных групп по отдельности с единым контролем: 3 модели × 7 режимов = 21 запуск. Стандартные аугментации YOLO оставались одинаковыми. Дополнительные группы: время суток, погода, сезон, камера, геометрия и перекрытия. Для ведущего x-чекпойнта получили: [S2]

Добавленная группа	HF, %	Kaggle, %	4 источника, %	Δ к контролю, п.п.
Контроль	67,83	55,81	36,36	+0,00
Время суток	65,56	53,75	35,12	-1,24
Погода	66,23	55,41	36,12	-0,24
Сезон	68,14	59,29	38,01	+1,65
Камера	65,25	53,93	35,35	-1,00
Дополнительная геометрия	58,80	51,68	32,47	-3,89
Перекрытия	68,07	56,23	36,81	+0,46

В колонке «4 источника» объединены HF, Kaggle и фиксированные подвыборки ExtCon/MOCS. В этом раннем протоколе в оценку входили и категории, которых не было в train. Поэтому его абсолютные значения нельзя напрямую сопоставлять с последующими таблицами по общим категориям.

Выводы получились содержательными. Season дал лучший pooled AP и улучшил Kaggle с 55,81% до 59,29%. Сильная геометрия ухудшила качество: её эффект складывался с уже существующими масштабированием, переносом и отражением в YOLO. Мы рассматривали повреждение признаков и слишком сильное изменение распределения как гипотезу, а не как доказанную единственную причину падения.

Далее выполнили ещё 15 запусков: контроль и четыре группы weather_light, camera_light, season, occlusion на трёх моделях. Погоду и камеру ослабили. Одновременно ввели явный протокол общих категорий: оцениваем позитивные bbox классов, встречавшихся в train; исключённые категории становятся ignore-регионами. Внутри этого нового протокола season для x поднял pooled AP с 54,72% до 57,01%. **Разницу между старым 36,36% и новым 54,72% нельзя считать улучшением модели: здесь изменилась постановка оценки.** [S3]

На этапе обучения полных исходных train оставили season. Позже, при адаптации на ExtCon/MOCS и целевом архиве, финальные YOLO обучали с мягкой встроенной геометрией и цветом, без Mosaic и без дополнительной season. Не нужно приписывать экспортированным YOLO весь набор аугментаций последнего классификатора. [S4, S9, S11]

5. Почему расширяли и пересматривали данные

Исходные датасеты решали задачу массового отбора моделей, но не полностью представляли целевой домен. В анализе train медианная короткая сторона bbox после масштабирования к 640 составляла 320 px у HF, около 53 px у Kaggle, 49 px у ExtCon и 29 px у MOCS. В MOCS около 28% bbox имели короткую сторону меньше 16 px. Эти исходные статистики включают исходную таксономию, в том числе людей в ExtCon/MOCS. Они объясняют направление проблемы, но не являются метрикой качества модели. [S9a]

Источник	Роль в проекте	Протокол данных
№1 Kaggle construction-equipment	Детекция и классификация, кадры со стройплощадок	Полный train, valid по имени пополам; в финальных моделях первая половина validation, вторая test
№6 HF constructionxc7c	Базовые категории техники и объём данных	Исходные train / valid / test

Источник	Роль в проекте	Протокол данных
№3 minicavconstruction-machines-images-dataset	Дополнительные примеры для классификатора	80/10/10, seed 42, разбиение источников до кропов
№4 construction-vehicle-images	Дополнительные изображения для классификатора	80/10/10 по доступным временным данным; аудит нашёл timestamps в именах и EXIF
№7 ExtCon	Сложные сцены, краны и расширение покрытия классов	80/10/10, seed 42, сплиты согласованы между YOLO и ConvNeXt
№7 MOCS	Многообъектные сцены и мелкие объекты	Отдельное 80/10/10, seed 42; стилизованные копии исключены
COCO + отдельные Hanging hook	Размеченные отрицательные примеры для unknown	Отдельные train/validation/test; неизвестные тестовые категории выделены отдельно
Целевой архив, 100 кадров	Адаптация к реальным ракурсам, в том числе буровые	80/10/10 по изображениям, один и тот же список для обеих частей каскада

Таксономию приводили через [construction_unified_mapping_v5.json](#). Ignore-категории удаляли по явному правилу. Bbox одного изображения попадали в один сплит. Точные байтовые и доступные пиксельные пересечения проверяли, train-копии held-out изображений исключали. Финальные половины Kaggle согласовали с ConvNeXt, чтобы её validation не стал тестом каскада. Это важное изменение относительно первого YOLO-скрининга. [S5-S8]

Проверка не устранила всю возможную зависимость кадров: аудит нашёл соседние даты и серии по обе стороны сплитов. Мы не называем этот benchmark независимой проверкой на новых стройплощадках. Для такого утверждения нужен отдельный split по площадкам, камерам и периодам. [S9a]

Краны и люди

В train MOCS 9 144 из 14 846 исходных bbox относились к людям. При одноклассовом обучении это давало большой вес людям, которые не являются целью задачи, поэтому в последних YOLO людей исключили из положительных целей. В ConvNeXt класс person сохранили, чтобы дополнительно отсеивать такие кропы на выходе.

Башенные краны размечены в ExtCon/MOCS, но HF/Kaggle не дают полноценной tower-разметки. Поэтому гипотезу отдельного tower-детектора проверяли на источниках с соответствующей разметкой, с положительными кадрами и сложными отрицательными примерами. Специалист повышал полноту, но устойчивого выигрыша всего каскада на test не показал. В итоговый передаваемый пакет вошли два общих YOLO и ConvNeXt. Отдельный специалист остался проверенной альтернативой, а не обязательной частью финальной архитектуры. [S9, S11]

6. Выбор классификатора

Сначала сравнили ResNet32/50/101, frozen DINOv2 ViT-B/14 и frozen CLIP ViT-B/32. Для DINOv2/CLIP не обучали параметры: использовали cosine weighted k-NN по train-эмбедам, k выбирали на validation. В варианте с аугментациями банк содержал оригинал и одну аугментированную версию кропа. Нельзя называть этот эксперимент полным fine-tuning DINOv2 или CLIP. [S5]

ResNet32 начинал с нуля, остальные обучаемые CNN - с ImageNet-весов. Поэтому слабый результат ResNet32 относится к этой конфигурации, а не доказывает непригодность архитектуры вообще. В первом цикле ResNet101 без аугментаций дал 93,23% micro F1, тогда как DINOv2 с аугментированным банком - 88,45%, CLIP - 75,57%. Для данной задачи специализированное дообучение оказалось сильнее этих вариантов поиска по эмбедам.

Затем добавили ConvNeXt-small и повторили сравнение с season + мягкой геометрией. Ниже все строки одного цикла и одного теста готовых кропов. [S6]

Модель	Без аугментаций: micro / macro F1, %	Season + geometry: micro / macro F1, %	Focus-13 macro F1 с аугами, %
ResNet32	68,64 / 40,85	72,66 / 50,04	58,96
ResNet50	92,20 / 77,91	90,53 / 74,39	80,62
ResNet101	93,23 / 78,80	92,29 / 76,85	82,73
DINOv2, frozen k-NN	88,25 / 72,54	88,23 / 72,02	76,04
CLIP, frozen k-NN	75,52 / 57,14	74,87 / 55,70	62,67
ConvNeXt-small	92,22 / 79,60	93,10 / 78,12	84,42

ConvNeXt + аугментации: micro F1 93,10%, macro F1 по приоритетным 13 категориям 84,42%. ResNet101 без аугментаций чуть лучше по общему micro F1 - 93,23%, но ниже по focus-13 macro F1 - 83,59%. Поэтому аргумент выбора ConvNeXt - сильный баланс качества по прикладным категориям и удобство дальнейшей адаптации, а не победа во всех столбцах.

В этих ранних таблицах drilling_rig ещё не имеет положительных примеров, хотя входит в фиксированный список классов. Его нулевой F1 влияет на macro. Последующую таблицу с добавленными буровыми нельзя использовать как чистое сравнение «та же выборка до/после».

7. Выбор финальных аугментаций ConvNeXt и отказ от мусора

Для unknown добавили размеченные объекты COCO вне целевой таксономии и небольшое количество непересекающихся Hanging hook. Из COCO исключали целые изображения с людьми или транспортом. Это лучше обосновано, чем объявлять любые пустые по неполной разметке участки фоном. Получилось 10 023 unknown train-кропа, 1 202 validation, 1 367 test. [S7]

Сравнили три режима с одинаковыми исходными весами и данными. Победителя выбирали по **validation loss**, до просмотра test. Loss отдельно взвешивал известные и unknown: 0,8 и 0,2.

Аугментации ConvNeXt	Validation loss ↓	Micro F1, известные, %	Macro F1, известные, %	Macro F1, focus-13, %
season_geometry	0.3920	95,35	80,62	86,06
weather_camera	0.3641	95,83	82,98	86,85
robust_crop	0.3795	95,61	82,92	86,65

Вариант weather_camera выиграл на validation: 0,3641 против 0,3920 и 0,3795. В нём season применяется с вероятностью 0,20, мягкая геометрия 0,25, погода 0,15, камера 0,20. Масштаб 0,9-1,1, перенос до ±5%, без поворотов, перспективы и Mosaic. Погода включает лёгкий дождь, снег и туман. Камера - умеренный blur, JPEG, шум и уменьшение разрешения. Геометрия применяется независимо; одновременно выбирается не более двух доменных групп.

Перекрытия и crop jitter в robust_crop не улучшили выбранную validation-функцию. Их не включили в последний классификатор. У кропов с любой стороной меньше 9 px аугментации пропускаются, а сами примеры сохраняются: это устраняет ошибки трансформаций на очень маленьких объектах.

Порог unknown калибруется по known-validation с ограничением $\leq 1\%$ ложных отклонений. Это ограничение на validation, а не универсальная гарантия на любых кадрах. Большинство отрицательных примеров - COCO, поэтому почти 100% unknown recall на таком тесте нельзя переименовать в «отсекаем почти 100% ложных bbox на стройке». [S7, S10]

8. Финальная адаптация с целевым архивом

100 изображений содержат 2 037 размеченных bbox, в том числе 568 сомнительных меток. По принятому протоколу их учитывали как обычные метки. Разметка автоматическая, без утверждения об экспертной очистке всего корпуса. Одинаковый split 80/10/10 зафиксировали для YOLO и ConvNeXt. Для YOLO исключили person, для классификатора сохранили все известные классы.

Финальная выборка	Train	Validation	Test
YOLO: изображения	36 391	3 598	2 832
YOLO: bbox техники	58 419	6 370	4 150
ConvNeXt: все кропы	79 502	8 993	7 101
Из них unknown	10 023	1 202	1 367
Буровые установки: известные кропы	82	11	13

Доля целевого архива в большом корпусе мала. Поэтому при обучении его повторяли $\times 10$, ExtCon в YOLO $\times 4$. Это увеличение частоты показа, а не новые уникальные фотографии. На validation/test повторов нет. Для последнего ConvNeXt 79 502 уникальных train-кропа превращаются в 94 262 предъявления за эпоху. [S10, S11]

Финальные YOLO начали с ранее адаптированных весов 640/960, затем продолжили обучение на полном объединённом корпусе. Это последовательная адаптация с возвратом старых данных, чтобы новый домен не полностью вытеснил старый. Она не доказывает отсутствие забывания: старые и новые источники оценивались отдельно.

Модель	Пройдено эпох	Лучшая эпоха	Остановка
YOLO26x 640	8	1	7 эпох без улучшения validation AP
YOLO26x 960	29	22	7 эпох без улучшения validation AP
Последняя ConvNeXt-small	7	1	6 эпох без улучшения validation selection loss

Это дообучение уже сильных весов. Лучшая первая эпоха у 640 и ConvNeXt означает, что дальнейшие эпохи не улучшили критерий выбора; сохранялась именно лучшая версия. У финальной ConvNeXt не было остановки по заданному числу эпох: сработал early stopping.

9. Что реально лучше у YOLO 960

Сначала сравним **одноклассовую детекцию без помощи классификатора**, все 2 832 test-изображения и 4 150 bbox техники. [S11]

Метрика детектора, test	YOLO 640	YOLO 960
Общий mAP@50-95	68,55%	68,16%
Общий AP@50	87,63%	87,12%
AP малых объектов, COCO small	15,58%	18,87%
AP средних объектов	50,72%	53,55%
mAP@50-95 на новом архиве	28,67%	30,00%

YOLO 960 улучшает AP малых объектов на **3,29 п.п.**: с 15,58% до 18,87%. Вход содержит в 1,5 раза больше пикселей по каждой стороне, что даёт разумную инженерную гипотезу для лучшей локализации небольших машин. Это объяснение механизма, а не отдельный эксперимент, изолирующий только разрешение: веса 640 и 960 проходили отдельное обучение.

Общий AP у 960 ниже на 0,39 п.п. Поэтому формулировка «960 лучше по общей точности на всех данных» не соответствует результатам.

Источник test	Изображения	YOLO 640, AP50-95, %	YOLO 960, AP50-95, %
HF constructionxc7c	757	78,43	78,45
Kaggle construction-equipment	1614	70,24	69,72
ExtCon	52	42,88	36,11
MOCS	399	60,36	62,47
Целевой архив	10	28,67	30,00

На ExtCon 960 уступает, на MOCS и целевом архиве выигрывает. Сохранять оба режима обоснованно: различия зависят от источника и масштаба объектов.

Весь каскад с последней ConvNeXt

Для этой подготовки дополнительно пересчитаны class-aware метрики из сохранённых предсказаний на тех же 20 отложенных кадрах. Порог unknown и правило scoring зафиксированы, ничего не подбиралось по этим результатам. Для AP score = уверенность YOLO × вероятность лучшего известного класса, unknown/person отклоняются. Raw AP повторно воспроизвёл прежние значения точно. [S12]

Каскад с последней ConvNeXt	YOLO 640	YOLO 960
Validation архива: mAP@50-95	33,81%	35,64%
Test архива: mAP@50-95	25,42%	26,38%
Test архива: AP@50	39,33%	37,61%
Test архива: precision при score ≥ 0,25	59,21%	63,89%
Test архива: recall при score ≥ 0,25	39,47%	40,35%
Test архива: F1 при score ≥ 0,25	47,37%	49,46%

Test здесь - **10 изображений, 114 bbox техники**. Validation - 10 изображений, 157 bbox. При фиксированном score 0,25 диагностический IoU равен 0,5. У AP используется COCO maxDets=100, у фиксированных диагностик maxDets=300. Порог score этих диагностик отличается от детекторного confidence-ползунка в визуальной галерее.

Таким образом, **960 улучшила end-to-end mAP@50-95 на целевом test на 0,96 п.п.** и на validation на 1,83 п.п. Но AP@50 на test ниже. Можно защищать 960 как улучшенную версию для данного целевого сценария по выбранной метрике mAP@50-95. Нельзя объявлять универсальное или статистически доказанное превосходство: здесь один split, 10 test-кадров, автоматическая разметка и ранее просматривавшиеся сцены.

Готовая формулировка для слайда: **«YOLO 960 повышает качество на малых объектах и сложных целевых кадрах: +3,29 п.п. AP small на общем test и +0,96 п.п. mAP@50-95 полного каскада на архивном test. YOLO 640 сохраняем как базовый режим с сопоставимым общим качеством».**



Иллюстрация: Screenshot_19 из validation, YOLO confidence $\geq 0,25$. На найденном bbox буровая получила класс drilling_rig. Один пример показывает формат результата, но не заменяет метрики по всему test.

10. Качество последней ConvNeXt

Оценка проводится на **готовых кропах истинных bbox**, всего 7 101 test-пример: 5 734 известных и 1 367 unknown. [S10]

Micro F1 суммирует TP, FP и FN по выбранным классам перед вычислением F1. Macro F1 сначала считает F1 каждого класса, затем усредняет их с одинаковым весом. Поэтому macro помогает заметить проблемы редких категорий, которые могут теряться за частыми классами.

Focus-13 задан ещё до этих экспериментов: самосвал, экскаватор, грейдер, каток, кран-манипулятор, ковшовый погрузчик, автобетоносмеситель, бульдозер, грузовик, автокран, башенный кран,

бетононасос и буровая установка. Это фиксированный прикладной набор, а не выбор лучших классов после просмотра результата.

Набор классов	Micro F1, %	Macro F1, %
Все 23, включая unknown	95,86	84,54
22 известных	95,32	83,92
13 приоритетных	95,48	91,82

Unknown recall - 99,85%, ложное отклонение известных test-кропов - 0,91%. На целевом test-архиве классификатор верно определил 134 из 167 готовых кропов, accuracy 80,24%. F1 буровых - 72,73% на 13 положительных примерах: 8 TP, precision 88,89%, recall 61,54%. До добавления архива положительных обучающих примеров drilling_rig в подготовленном корпусе не было.

Что важно для ответов жюри: добавление буровых не улучшило все старые классы. На одинаковых 6 934 старых test-кропах known macro F1 снизился с 82,98% до 81,43%, micro F1 - с 95,83% до 95,75%. Поэтому последняя версия расширяет покрытие и адаптируется к целевым изображениям, но не является безусловным улучшением каждой категории.

Нельзя подписывать 95,86% как «точность распознавания техники на фотографиях»: это micro F1 классификации кропов, включая unknown, на объединённом наборе. Финальная оценка полного каскада 960 на целевом test - другая задача и составляет 26,38% mAP@50-95.

11. Как связать этот рассказ с критериями жюри

Критерий ТЗ	Что показать в ML-блоке	Что дополнить демонстрацией проекта
8.1: обоснованность подхода и технологий	Отбор 35 чекпойнтов, проверка каскада, таблица классификаторов	Почему наблюдение конкретной техники полезно для конкретного этапа
8.2: модульность и масштабирование	Независимые detector/classifier, единый mapping, переносимый инференс	Контракт API, хранение camera/time/zone, подключение новых камер
8.2: скорость	Сохранённые замеры YOLO, crop, classifier отдельно	Серия замеров на целевом компьютере с одинаковыми настройками, p50/p95
8.3: устойчивость распознавания	Метрики по источникам и размерам, bbox на held-out кадрах	Примеры дождя, зимы, дальних объектов, трудных ошибок
8.3: логика и объяснимость предупреждений	bbox, категория, уверенность, unknown вместо принудительного класса	Правило «этап → техника» и подтверждающий снимок
8.4: документация и воспроизводимость	Beca, SHA256, порог, requirements, predict.py, loss-графики и логи	Пошаговый запуск всего сервиса
8.5: ясность и наглядность	Короткий рассказ и одно сравнение 640/960 на одинаковом кадре	Полный сценарий от загрузки снимка до понятного предупреждения

ТЗ не даёт числовых весов критериев и не обещает максимальный балл за конкретный AP. ML-метрики поддерживают защиту, но не заменяют продуктовую демонстрацию. [S0]

Пример интерфейса между модулями: событие содержит идентификатор камеры, время снимка, зону, bbox и категорию. Для этапа «разработка котлована» правила могут ожидать экскаватор и самосвалы. Если модель не нашла самосвал, корректная формулировка сигнала - «самосвал не обнаружен в наблюдаемой зоне», а не «самосвала на площадке нет». Проверка нескольких кадров и достаточности

обзора - рекомендуемое развитие логики, здесь не заявляется как уже реализованный результат обучения.

Рекомендации для пилота по камерам следуют из ошибок: обеспечить обзор рабочей зоны без крупных постоянных перекрытий, избегать чрезмерно дальних планов, где техника теряет детали, контролировать смаз и засветку, сохранять время и идентификатор камеры. Высоту, оптику и допустимый размер объекта в пикселях нужно подтвердить полевым тестом, не выдавать произвольные числа за установленный норматив.

12. Короткие ответы на сложные вопросы

Почему не только YOLO с классами? Проверили оба подхода. Каскад дал небольшой pooled-выигрыш в одном сопоставимом системном эксперименте и заметный выигрыш на ExtCon. Он позволяет отдельно развивать категории и отказ от unknown. Дополнительные данные классификатора входят в объяснение результата.

Почему не CLIP или DINOv2? Проверили frozen-эмбединги с k-NN, а не все возможные способы их использования. В этих конфигурациях fine-tuned CNN дали лучший результат. Это достаточно для практического выбора, но не для универсального вывода об архитектурах.

Почему 960 лучше, если общий AP ниже? Улучшение относится к малым объектам и целевому архивному сценарию. По общей метрике 640 и 960 сопоставимы, причём 640 немного выше. Мы прямо показываем обе стороны сравнения.

Почему классификация около 95%, а каскад около 26%? Это разные задачи, выборки и метрики. Классификатор получает готовый правильный кроп. Каскад сначала должен найти объект, правильно провести границы и определить класс. mAP@50-95 также проверяет качество локализации на нескольких IoU.

Есть ли утечка? Проверены точные и пиксельные дубли, сплиты детектора и классификатора согласованы. Но встречаются связанные сцены и даты, а benchmark использовался в исследованиях неоднократно. Отдельный тест на новых площадках ещё нужен.

Почему не сохранили все аугментации? Проверяли группы отдельно и контролировали validation. Сильная геометрия ухудшала YOLO, а robust_crop проиграл выбранному validation-критерию ConvNeXt. Больше преобразований не означает лучше.

Насколько надёжен unknown? Порог калиброван с ограничением ложных отклонений, но отрицательный test в основном состоит из COCO-примеров. На произвольном строительном мусоре нужна отдельная проверка.

Почему пока невысокий результат на архиве? Кадры отличаются от массовых обучающих источников, содержат мелкие и перекрытые объекты. Целевая разметка автоматическая, test мал. Следующие шаги - экспертная проверка меток, больше редких классов и независимый тест по площадкам.

Источники чисел и утверждений

Все пути ниже относительно корню проекта. Полные исходные таблицы приложены в папке [tables](#). Результаты разных этапов не объединяются в одну кривую роста, если менялись классы, данные или протокол.

- [S0] Приложенное T3, PDF, разделы 2, 4, 5 и 8. Шаблон PPTX, слайды 3-5, 8-11, 12-29: структура и стиль, а не источник ML-метрики.
- [S1] [jepa-yolo/README.md](#), [jepa-yolo/results/dashboard/bbox_mAP50_95_Nx3.csv](#), [collection.json](#).
- [S2] [jepa-yolo-augs/README.md](#), [results/dashboard/*mAP50_95_3x5.csv](#).
- [S3] [jepa-yolo-lightcommon/README.md](#), [results/dashboard/*mAP50_95_3x5.csv](#).

- [S4] [jepa-yolo-full-season/README.md](#), [results/dashboard/season_mAP50_95_3x3.csv](#).
- [S5] [construction-classifiers/README.md](#), [results/dashboard/f1_10x4.csv](#).
- [S6] [construction-classifiers-season/README.md](#), [results/dashboard/f1_12x4.csv](#).
- [S7] [jepa-net/README.md](#), [results/comparison.csv](#), [SESSION_COMPLETE.json](#).
- [S8] [jepa-yolo-extcon-mocs/README.md](#), [jepa-yolo-extra10/results/yolo/dashboard/class_aware_mAP50_95_2x5.csv](#).
- [S9] [jepa-yolo-domain-repair/README.md](#), [RESULTS.md](#), [results/yolo/system_selection.json](#).
- [S9a] [diagnostics/yolo-domain/train_summary.json](#), [deep_summary.json](#), [REPORT.md](#).
- [S10] [jepa-net-archive-mix/results/RESULTS.md](#), [VERIFICATION.json](#), [combined_data_summary.json](#), [archive_summary.json](#), [selected/reject_threshold.json](#).
- [S11] [jepa-yolo-archive-mix/results/yolo/RESULTS.md](#), [data_audit.json](#), [technology_640/test/metrics.csv](#), [technology_960/test/metrics.csv](#), [COMPLETE.json](#) соответствующих моделей.
- [S12] [presentation-story/research/latest_cascade/metrics.csv](#), [protocol.json](#). Новый пересчёт по [archive-holdout-detection/classified/predictions.json](#); SHA256 входа сохранён. Код пересчёта: [presentation-story/research/evaluate_latest_cascade.py](#).
- [S13] [exports/jepa-models-2026-09-28/README.md](#), [manifest.json](#), [SMOKE_TEST.json](#), [predict.py](#).